MACHINE LEARNING

House Price Prediction

Supervised Learning · Regression Task

Taha Messelmani · Manel Souissi

Problème & Objectif

POURQUOI

- Les prix influencés par surface, qualité, ancienneté, quartier
- Les acheteurs & vendeurs ont besoin d'évaluations objectives
- L'expertise traditionnelle est lente et inconsistante
- Le ML automatise et améliore la précision tarifaire

LE PROJET

JEU DE DONNÉES

1 460 maisons · 80 variables · Ames, Iowa

OBJECTIF

Prédire le prix de vente final ($)

APPROCHE

Pipeline ML complet — EDA → Modélisation

MÉTRIQUES

Score R^2 + RMSE

Comprendre les Donnees

Avant de construire un modele, on explore : structure, distributions et correlations.

1 Structure du Jeu de Donnees

1 460 maisons

chaque maison = 1 observation

80 variables

taille, qualite, localisation, annee...

2 types de variables

numeriques (surface...) et categorielles (quartier...)

19 colonnes incompletes

valeurs manquantes a corriger avant modelisation

2 Distribution des Prix

Prix : 35 K$ a 755 K$

grande variabilite entre maisons

Courbe asymetrique a droite

quelques maisons tres cheres tirent la moyenne vers le haut

Transformation log appliquee

rend la distribution plus symetrique

Majorite entre 100-250 K$

zone centrale la plus representee

3 Correlations avec le Prix

Qualite globale : n1

variable la plus liee au prix de vente

Surface habitable : n2

plus la maison est grande, plus elle est chere

Annee de construction

maisons plus recentes = prix plus eleves

Quartier

la localisation influence fortement le prix

Nettoyage des Données

Avant d'entrainer le modele, les donnees brutes doivent etre nettoyees et corrigees.

1 Valeurs Manquantes

Le probléme : 19 colonnes contiennent des donnees vides.

La solution : Remplissage intelligent : mediane pour les chiffres, mode pour les categories. Ex : colonne piscine = 'Sans piscine' au lieu de vide.

2 Valeurs Aberrantes

Le probléme : Certaines maisons de mauvaise qualite ont des prix tres eleves -- elles faussent le modele.

La solution : Detection par graphiques (nuages de points). 4 outliers extremes supprimés pour ne pas biaiser l'apprentissage.

3 Distribution Asymetrique

Le probléme : Les prix de vente sont tres etales vers le haut (quelques maisons tres cheres).

La solution : Application d'une transformation logarithmique log(prix). Cela rend la distribution plus equilibree et ameliore les performances.

4 Pourquoi c'est crucial

Donnees brutes : bruit, valeurs extremes et trous = apprentissage biaise et predictions erronees.

Apres nettoyage : le modele apprend les vrais patterns et non des anomalies. C'est la base de tout bon modele ML.

04 Insights Cles

Ce que les donnees révelent sur les prix

Qualite & Surface

expliquent 35%+ de la variation du prix

Qu'est-ce que l'importance ?

C'est le pourcentage de la variation du prix qui est expliquee par chaque variable. Plus le % est eleve, plus la variable est utile pour predire le prix.

IMPORTANCE DES VARIABLES (% de variation du prix expliquee)

#1 Qualite Globale

Ex: note de 1 a 10 sur la finition

14.2%

#2 Surface Totale

Sous-sol + RDC + etages

11.8%

#3 Surface Habitable

Surface de vie principale

9.8%

#4 Qualite x Surface

Variable creee : interaction

8.2%

#5 Annee Construction

Plus recent = prix plus eleve

7.1%

#6 Capacite Garage

Nombre de voitures

5.8%

Feature engineering

On cree de nouvelles variables a partir des donnees existantes pour mieux capturer l'information et ameliorer les predictions.

11

nouvelles variables creees

- # = ranking of importance
- % = contribution to prediction
- Top 10 / 15 = among most important features

TotalSF

#2 - 11,8%

Surface totale = sous-sol + RDC + etage(s).
Capture mieux la taille reelle de la maison.

AncienneteReno

Top 15

Annees depuis la derniere renovation.
Une renovation recente augmente la valeur percue.

Anciennete

Top 10

Nombre d'annees depuis la construction.
Une maison de 10 ans vaut plus qu'une de 50 ans.

TotalSalles

Top 10

Somme ponderee de toutes les salles de bain.
Plus de salles = maison plus grande et plus chere.

QualitySF

#4 - 8,2%

Qualite x Surface habitable.
Combine deux facteurs cles en une seule variable.

ScoreQuartier

Top 15

Score moyen de qualite du quartier.
Capture l'effet de localisation de facon chiffree.

+ 5 INDICATEURS BINAIRES (Oui/Non) - HasPool - HasGarage - HasBasement - HasFireplace - Remodeled

APPROCHE DE MODÉLISATION

Tester plusieurs modèles · Sélectionner le meilleur

MEILLEUR MODÈLE

Gradient Boosting

R^2

0.905

RETENU

Random Forest

R^2

0.872

RETENU

Régression Lasso

R^2

0.871

Gradient Boosting surpasse systématiquement les autres, atteignant le R^2 le plus élevé : **0.905**

RÉSULTATS

Finaux

Gradient Boosting
RandomizedSearchCV
5-Fold Cross-Validation

90.5%	**Précision** Variance du prix expliquée
0.905	**R^2 Score** Validé par cross-validation
0.118	**RMSE (log)** Erreur quadratique moyenne
0.082	**MAE** Erreur absolue moyenne

CE QUE NOUS AVONS ACCOMPLI

1. Le modèle explique 90,5 % de la variation des prix — haute puissance prédictive
2. Erreur typique : ±12 000 $ sur une maison médiane de 163 000 $
3. Qualité + Surface = les deux facteurs les plus influents
4. Pipeline complet : EDA → Nettoyage → Ingénierie → Modèle optimisé

Gradient Boosting

R^2 = 0.905 · Prédiction du Prix de l'Immobilier