MACHINE LEARNING

House Price Prediction

Supervised Learning · Regression Task

Taha Messelmani · Manel Souissi

Problème & Objectif

POURQUOI

- Les prix influencés par surface, qualité, ancienneté, quartier
- Les acheteurs & vendeurs ont besoin d'évaluations objectives
- L'expertise traditionnelle est lente et inconsistante
- Le ML automatise et améliore la précision tarifaire

LE PROJET

JEU DE DONNÉES

1 460 maisons · 80 variables · Ames, Iowa

OBJECTIF

Prédire le prix de vente final ($)

APPROCHE

Pipeline ML complet — EDA → Modélisation

MÉTRIQUES

Score R^2 + RMSE

Analyse Exploratoire

E D A

FORME DU JEU DE DONNÉES

1 460 maisons analysées · 80 variables par maison

Mix numérique & catégoriel · 19 colonnes avec valeurs manquantes

DISTRIBUTIONS

Prix : 35 K$ – 755 K$ · Distribution asymétrique à droite

Log-transformation appliquée · Majorité : 100 K$ – 250 K$

CORRÉLATIONS

Qualité globale : 1er prédicteur · Surface habitable : 2e rang

Année de construction : forte · Quartier : impact significatif

Prix Médian

163 K$

Ames, Iowa

Asymétrie corrigée par

log(x)

Nettoyage des Données

Préparation avant tout entraînement du modèle

Valeurs Manquantes

19 colonnes incomplètes.
Remplissage médiane (num.) ou mode (catég.).
Contextuel : « Sans Piscine » vs vide.

Valeurs Aberrantes

Maisons extrêmes faussent le modèle.
Détection via nuages de points.
4 outliers supprimés (qualité vs prix).

Distribution Asymétrique

Prix de vente asymétrique à droite.
Log-transformation appliquée.
Normalise la cible → meilleures perfs.

Pourquoi c'est crucial

Données brutes = mauvaises prédictions.
Le nettoyage permet d'apprendre
les vrais patterns, pas le bruit.

Insights Clés

Ce que les données révèlent sur les prix

Qualité & Surface

dominent avec 35%+ de la variation du prix

IMPORTANCE DES VARIABLES (TOP 6)

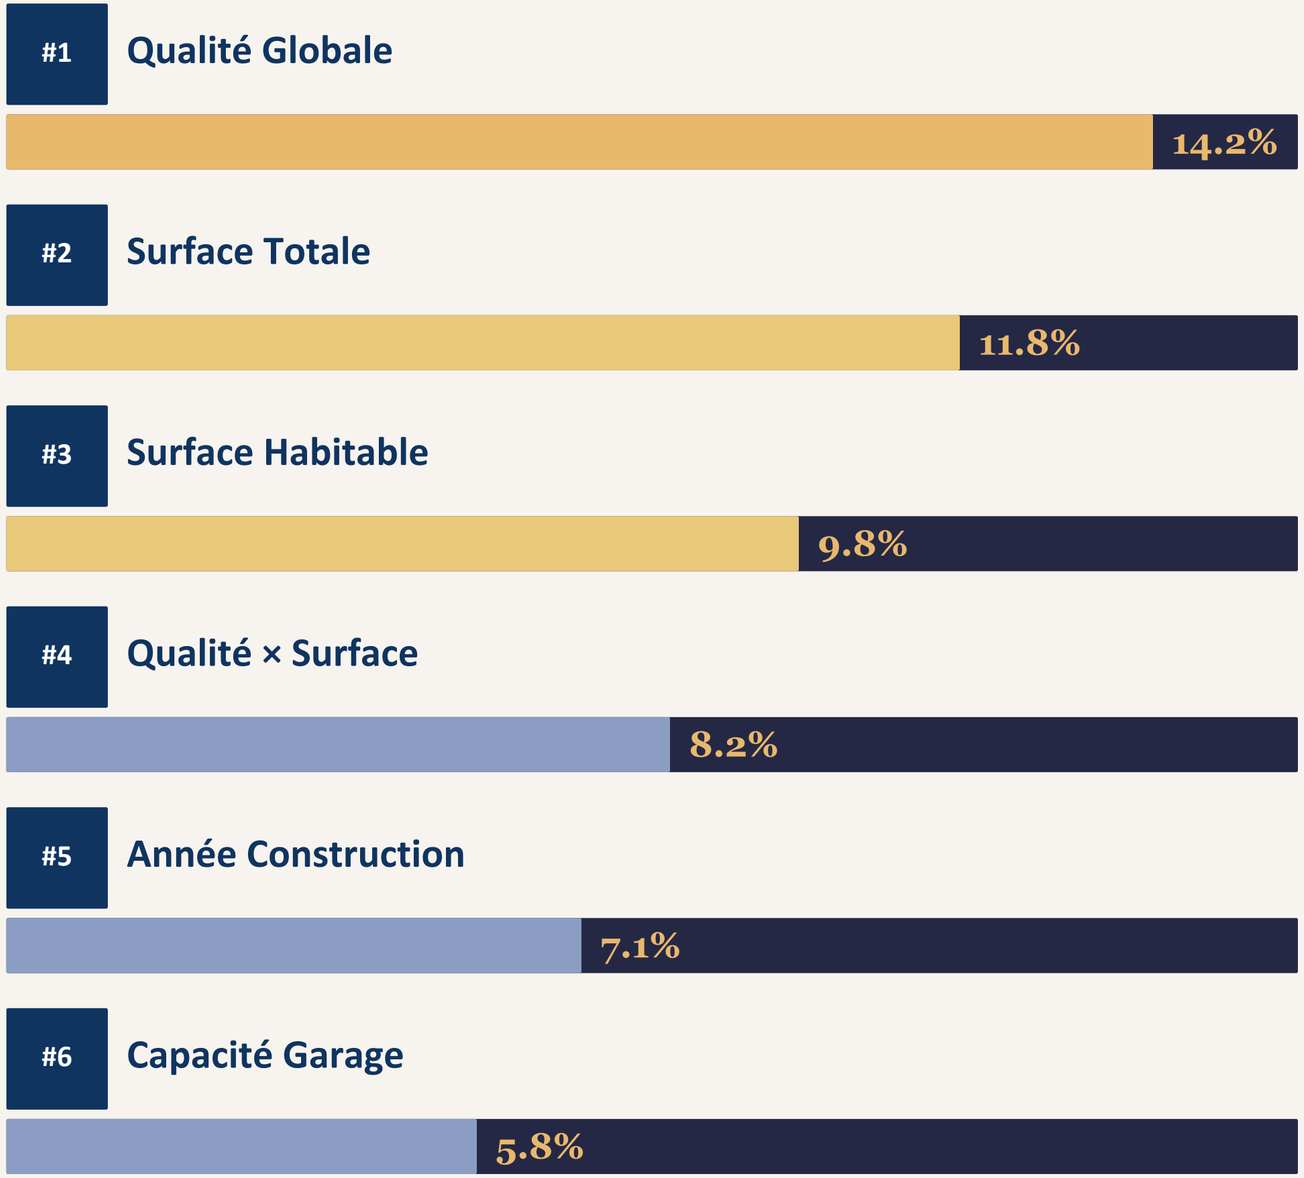

Ingénierie des Variables

Nouvelles variables créées pour améliorer les performances du modèle

11
nouvelles variables

TotalSF
#2 · 11,8%

Sous-sol + RDC + Étage

Ancienneté
Top 10

Années depuis la construction

QualitySF
#4 · 8,2%

Score qualité × Surface habitable

AnciennetéRéno
Top 15

Années depuis la dernière rénovation

TotalSalles
Top 10

Somme pondérée des salles de bain

ScoreQuartier
Top 15

Score de qualité du quartier

+ 5 INDICATEURS BINAIRES · HasPool · HasGarage · HasBasement · HasFireplace · Remodeled

APPROCHE DE MODÉLISATION

Tester plusieurs modèles · Sélectionner le meilleur

MEILLEUR MODÈLE

Gradient Boosting

R^2

0.905

RETENU

Random Forest

R^2

0.872

RETENU

Régression Lasso

R^2

0.871

Gradient Boosting surpasse systématiquement les autres, atteignant le R^2 le plus élevé : **0.905**

RÉSULTATS

Finaux

Gradient Boosting
RandomizedSearchCV
5-Fold Cross-Validation

90.5%	**Précision** Variance du prix expliquée
0.905	**R^2 Score** Validé par cross-validation
0.118	**RMSE (log)** Erreur quadratique moyenne
0.082	**MAE** Erreur absolue moyenne

CE QUE NOUS AVONS ACCOMPLI

1. Le modèle explique 90,5 % de la variation des prix — haute puissance prédictive
2. Erreur typique : ±12 000 $ sur une maison médiane de 163 000 $
3. Qualité + Surface = les deux facteurs les plus influents
4. Pipeline complet : EDA → Nettoyage → Ingénierie → Modèle optimisé

Gradient Boosting

R^2 = 0.905 · Prédiction du Prix de l'Immobilier